

PROBLEMA Y SOLUCIÓN: DESARROLLANDO UN PROYECTO BIG DATA

PRESENTACIÓN

¿Tener grandes cantidades de datos es suficiente para tomar mejores decisiones? En realidad, una solución Big Data comienza mucho antes de procesar información: primero necesitamos comprender el problema, identificar qué valor esperamos generar y definir qué datos, tecnologías y componentes serán necesarios para construir una solución viable.

Durante este Sprint asumirás junto con tu equipo el reto de formular y comenzar a diseñar un proyecto Big Data, integrando los aprendizajes de las diferentes unidades didácticas. Analizarán necesidades reales, definirán el alcance del proyecto, identificarán requerimientos de información, diseñarán su arquitectura inicial y evaluarán aspectos relacionados con datos, calidad, factibilidad, desarrollo e integración tecnológica. Cada actividad permitirá transformar progresivamente una necesidad empresarial en una propuesta tecnológica estructurada y sustentada.

OBJETIVO

Formular, diseñar y desarrollar la propuesta inicial de un proyecto Big Data a partir de una necesidad empresarial, integrando criterios de gestión de proyectos, factibilidad, calidad, análisis de datos y arquitectura tecnológica, con el propósito de establecer una base sólida para su posterior implementación y evolución durante los siguientes Sprints.

METODOLOGÍA



Este Sprint se desarrollará bajo la metodología de Aprendizaje Basado en Proyectos (ABP). Los estudiantes trabajarán principalmente en equipos sobre un proyecto Big Data, integrando los conocimientos y capacidades desarrollados en las diferentes unidades didácticas para resolver progresivamente un mismo reto.

El trabajo seguirá una dinámica incremental: analizar el problema, formular el proyecto, definir requerimientos, evaluar su viabilidad, diseñar la arquitectura, obtener y analizar datos y plantear los primeros componentes de la solución tecnológica. Durante el Sprint se realizarán actividades prácticas, investigación aplicada y asesorías que permitirán

recibir retroalimentación, justificar decisiones y mejorar continuamente la propuesta, promoviendo el pensamiento crítico, la colaboración y la toma de decisiones fundamentadas.

STACK TECNOLÓGICO

TECHNOLOGY	TYPE	TOOL	VERSIÓN	Patterns / Best Practices
PROTOTYPE	Design	Figma		
DATABASE	Modeler	Vertabelo		
	Containers	Docker		
	Relational	SQL Server (<i>on-promise / cloud</i>)	2019 - developer	
	Management	SQL Server Management		
PROGRAMMING (<i>back-end</i>)	IDE Frameworks	IntelliJIDEA Visual Studio Code Spring Boot	Latest Latest Latest	
PROGRAMING (<i>front-end</i>)	IDE Frameworks	Visual Studio Code Angular (<i>front-end</i>) Node	Latest 19 + 22.14.0	
	Language	Java JavaScript	17 + Last version	
	Gestor	Maven	Latest	
	Frameworks	Bootstrap	5	
CLOUD PROVIDER	Repository	GitHub		
	Workspace	Drive		

ACTIVIDADES DEL SPRINT

ORIGEN	ACTIVIDADES	Ptos	EVIDENCIA
APS (JC) ADMINISTRACIÓN DE PROYECTOS DE SISTEMAS	Planificación, ejecución y revisión de cumplimiento de actividades de sprint	2	Actividad en Equipo → <u>Describir en el informe de sprint el seguimiento de la ejecución del sprint planificado:</u> el equipo ejecutará el Sprint definido, registrando el avance de las User Stories mediante los resultados y evidencias generadas, identificando las desviaciones encontradas y los riesgos que puedan afectar el cumplimiento del Sprint Global, así como su impacto y las acciones previstas para gestionarlos. (1 pto) → <u>Verificar y preparar la aceptación de los resultados:</u> a partir de lo ejecutado en el Sprint, el equipo verificará en el informe de Sprint que las evidencias generadas cumplen los criterios de aceptación definidos para cada User Story, clasificando cada criterio como cumple, no cumple o pendiente. Asimismo, registrará las observaciones y determinará las acciones necesarias para completar o corregir los resultados antes de su aceptación. Se sugiere complementar con una tabla de

ORIGEN	ACTIVIDADES	Ptos	EVIDENCIA
			resumen con los siguientes datos: US, Criterio de aceptación, Evidencia (breve descripción), Resultado, Observación y Acción a realizar (completar/Revisar) (1 pto).
EIT (FM) EMPREDIMIENTO DE INNOVACIÓN TECNOLÓGICA	Diseño y Validación del Modelo de Negocio Tecnológico	2	Actividad en Equipo Cada equipo desarrollará y validará las bases estratégicas, operativas y financieras de su emprendimiento tecnológico, iterando sobre su propuesta de valor a partir de la retroalimentación real del usuario. El proyecto se entregará mediante un lienzo interactivo centralizado en MURAL y una presentación ejecutiva grabada en video. Zona A: Lienzo de Propuesta de Valor (Value Proposition Canvas) - Mapa del perfil del cliente (Trabajos, Frustraciones y Alegrías). - Mapa de valor (Productos/Servicios, Aliviadores de dolor y Creadores de alegría). Zona B: Business Model Canvas (BMC de 9 Bloques) - Desarrollo completo e integrado de los 9 bloques adaptados al modelo tecnológico (SaaS, App, Marketplace, etc.). Condición de entrega: - El enlace enviado debe tener permisos de acceso público de lectura o edición (Visitor Link) activo. (1 pto). - Presentación de video 4 a 6 minutos máximo. Enlace. (1 pto).
FCS (LM) FUNDAMENTOS DE CALIDAD DE SOFTWARE		3	Actividad en Equipo Crear la primera versión base del proyecto grupal de Big Data usando Java 17, Spring Boot WebFlux y Apache Spark, aplicando la estructura brindada como guía, control de versiones con GitFlow y evidencia de participación de todos los integrantes. El README debe explicar brevemente: → Nombre del proyecto. → Integrantes del grupo. → Objetivo del proyecto. → Problema que resolverá el proyecto. → Tecnologías usadas. Adicionalmente, deben generar la release 1.0.0 junto a la tag v1.0.0, para evidenciar todo lo trabajado durante el sprint. Todos los integrantes del grupo deben tener commits visibles en el repositorio. No se aceptará que un solo integrante suba todo el avance.

ORIGEN	ACTIVIDADES	Ptos	EVIDENCIA
TBD (JC) TALLERES DE BIG DATA	Big Data Challenge: De la Ingesta Cruda al Valor de Negocio	3	Actividad en Equipo Los estudiantes organizados en equipo deben: → Elaborar y describir la arquitectura del proyecto de Big Data: El diagrama debe mostrar claramente el flujo: Fuente Externa, Google Colab (Motor de Ingesta), AWS S3 (Carpeta: Raw/Bronze), Google Colab (Motor de Procesamiento) y AWS S3 (Carpeta: Silver) → Desarrollo e implementación de pipeline de ingesta de datos (utilizando Python en Google Colab) para extraer la información desde la fuente de origen y almacenarla en la capa Raw/Bronze del servicio Amazon S3. → Elaborar una tabla resumen con el estado inicial de los datos obtenidos y definir los criterios de calidad a evaluar, basándose en las 5 dimensiones tratadas en clase. → Desarrollar e implementar un pipeline de limpieza de datos, aplicando los criterios de calidad definidos, para procesar y migrar la información desde la capa Raw/Bronze hacia la capa Silver. → Investigar y describir los fundamentos de la capa Gold dentro de la Arquitectura Medallón y, basándose en esa investigación, desarrollar e implementar un pipeline en Python que transforme los datos limpios de la capa Silver en un modelo de datos consolidado, agregado y orientado a responder preguntas de negocio. Elaborar un video en equipo con cámara activa en donde cada integrante de equipo describa y explique cada una de las actividades solicitadas, pueden apoyarse con una presentación, tener presente que lo importante es demostrar la realización de cada actividad y no lectura del informe de sprint. (3 pts)
EIA (MV) ESTADÍSTICA INFERENCIAL APLICADA		2	Actividad en Equipo / Actividad Individual Pendiente: actividad por confirmar
FIA (JuC) FUNDAMENTOS DE INTELIGENCIA ARTIFICIAL	Integración de GitHub y Databricks, conexiones, instalación de Databricks CLI y uso de Volumen en Databricks.	3	Actividad Individual 1) Crear un repositorio GitHub y configurar un Pipeline con GitHub Actions para sincronizarlo mediante un Git Folder en tu cuenta de Databricks. 2) Habilitar 3 conexiones exitosas y diferentes, ejemplo: Drive, GitHub, Amazon S3, Database, etc. 3) Instalar Databricks CLI (Install Databricks) en tu equipo local y conectarse mediante una terminal, utilizando las credenciales de HOST y TOKEN de tu cuenta de Databricks. 4) Utilizar un Volumen en Databricks para subir imágenes y PDF, para vincularlo en un Catálogo ya existente. Entregable evidencia: ✓ Repositorio GitHub con el código fuente (1 punto) ✓ Descripciones y capturas de evidencia.

ORIGEN	ACTIVIDADES	Ptos	EVIDENCIA
			☒ Video individual en youtube y/o Drive, demostrando los 4 puntos anteriores (2 puntos).
SDE (VC) SISTEMAS DISTRIBUIDOS Y ESCALABLES	Investigación y aplicación de patrones para sistemas distribuidos y escalables	3	Actividad en equipo El estudiante deberá: • Diseñar en Figma el prototipo del dashboard para la visualización de los datos procesados en la capa Gold. • Organizar la información de acuerdo con las preguntas de negocio definidas en el proyecto. • Incorporar los principales elementos de visualización necesarios para facilitar el análisis de los datos. • Incluir filtros y opciones de consulta que permitan explorar la información de manera clara e intuitiva. • Mantener coherencia entre el dashboard propuesto, el modelo de datos de la capa Gold y los resultados que se espera obtener. Evidencias • Capturas del prototipo funcional del dashboard en Figma – (2 pto) • Enlace al prototipo en Figma – (1 pto)
CII (HR) COMUNICACIÓN INTERPERSONAL EN INGLÉS	LECTURA: The Internet	2	Actividad Individual La siguiente actividad : Reading Comprehension “The Rise of the World Wide Web” ,comprender la lectura y responder los siguientes ejercicios planteados dentro del informe.(1p). 1. Was the Internet built for science geeks or the general public? What about the World Wide Web? 2. Did online communities exist before the World Wide Web? If so, can you give some examples? 3. Do you think the Web will ever go away? Will it be ever replaced by something better? -Luego resolver las preguntas y elaborar un audio, teniendo en cuenta que debes compartir el link del archivo drive con hebert.rivera@vallegrande.edu.pe .(1p).

REQUISITO MÍNIMO

- Para la revisión del informe de sprint, es indispensable que se **apliquen** [Lineamientos Institucionales Basados en APA 7 para informes de Sprint en formato Digital](#), cabe precisar que, en caso no se apliquen estos lineamientos **se evidenciará descontando 2 puntos sobre la nota obtenida en cada entregable**.
- Describir cada una de las actividades dentro del mismo documento del informe y **no se aceptarán enlaces a archivos externos** a no ser que esto sea solicitado explícitamente en el guión del informe.
- Las actividades que realizas en otras plataformas (Mural, Miro, GitHub, etc) deberán evidenciarse adjuntado por lo menos 1 imagen y enlace a la actividad desarrollada en dichas plataformas y/o herramientas tecnológicas.

COMPROMISO DEL ESTUDIANTE

- Elaborar un informe, siguiendo el esquema adjunto; entregarlo el día [**fecha-entrega**].

- Hora máxima de entrega: [hora-entrega].
- Canal de entrega: Classroom de Experiencias Formativas en Situaciones Reales de Trabajo
- Participar en las reuniones de orientación por la Docente Monitor responsable.

FECHAS DE LAS REUNIONES DE ASESORÍAS

N°	FECHA HORA	MODALIDAD	ACTIVIDADES
1	29-septiembre-2026 11:00 am a 12:30 pm	Virtual - Q10	APS + EIT
2	02-octubre-2026 09:00 am a 10:30 am	Virtual - Q10	FCS + TBD + EIA
3	06-octubre-2026 11:00 am a 12:30 pm	Virtual - Q10	FIA + SDE + CII

FECHAS DE LOS ENTREGABLES

UD	DOCENTE	N° ENTREGABLE	FECHA Y HORA DE ENTREGA	PUNTOS
APS	Jesús Canales	1	29/Sept/2026 10:00 pm	2
EIT	Fátima Matos	1	29/Sept/2026 10:00 pm	2
FCS	Luis Manzo	2	05/Oct/2026 10:00 pm	3
TBD	Jesús Canales	2	05/Oct/2026 10:00 pm	3
EIA	Miguel Vargas	2	05/Oct/2026 10:00 pm	2
FIA	Juan Condori	3	08/Oct/2026 10:00 pm	3
SDE	Valery Chumpitaz	3	08/Mar/2026 10:00 pm	3
CII	Hebert Rivera	3	08/Mar/2026 10:00 pm	2